
UNIVERSIDADE DE SÃO PAULO

SCC0282 RECUPERAÇÃO DE INFORMAÇÃO

Trabalho Prático 1

Desenvolvimento e Análise de Modelos Clássicos de Recuperação de Informação

STUDENT

Ariel Alves da Silva (8847378)
Student 2 (student2_id)

DATE

September 23, 2026

Contents

Introdução	2
Técnicas utilizadas	3
Modelo Probabilístico BM25	3
Modelo Vetorial	3
Avaliação dos modelos	4
Resultados obtidos e Análise	4
Comparação entre Modelo Vetorial e Modelo Probabilístico	4
Curva Precision x Recall	4
Comparação de MAP	7
Análise por consulta	7
Consultas com BM25 superior	7
Consultas com Modelo Vetorial superior	8
Consultas com desempenho insatisfatório em ambos	8
Variação de parâmetros do BM25	9
MAP agrupado por parâmetros	9
Mapa de bolhas P@10 x R@10	10
Modificação de queries	11
BM25	12
Modelo vetorial	13
Análise de erros	14
Top 1 não relevante para BM25	14
Top 1 não relevante para modelo vetorial	15
Documento relevante omitido no modelo vetorial	16
Conclusão	17
Uso de ferramentas de IA	18

Introdução

Este trabalho consiste na implementação e análise de um sistema de Recuperação Textual utilizando dois modelos clássicos de recuperação da informação: modelo vetorial e modelo probabilístico. Ao analisar e comparar os dois modelos, é esperado obter uma distinção clara de classificação diante de uma base de dados real, fazendo uso de métricas exclusivas para avaliação de sistemas de Recuperação da Informação.

O sistema consiste basicamente em 4 etapas:

1. Processamento de documentos
2. Criação de posting lists
3. Processamento de query
4. Aplicação de query em modelos de RI

Todas foram implementadas na linguagem Python.

Técnicas utilizadas

Para a recuperação de documentos utilizando os modelos clássicos, criam-se as posting-lists a partir do dataset. Elas posteriormente são passadas aos modelos junto com a query, que por sua vez realizam a recuperação de documentos e retornam o ranking com IDs dos documentos, métricas, score e relevância.

A implementação optou por definir a Posting List, o Modelo Vetorial e Modelo Probabilístico e os Experimentos como classes. Como vários parâmetros e configurações são testados, é a melhor forma de simplificar e organizar o código.

O resto da implementação segue como funções simples divididas em documentos.

Modelo Probabilístico BM25

O modelo probabilístico BM25 consiste na seguinte função de ranqueamento:

$$\text{score}(d, q) = \sum_{t \in q} \text{IDF}(t) \frac{tf(t, d)(k_1 + 1)}{(tf(t, d) + k_1 \left(1 - b + \left(\frac{b(|d|)}{\text{avgdl}}\right)\right))}$$

- $tf(t, d)$ - Frequência do termo no documento
- k_1 - Parâmetro de controle da saturação
- b - Parâmetro de controle da influência do tamanho do documento
- $|d|$ - Tamanho do documento

Onde:

$$\text{IDF}(t) = \log \left(1 + \frac{N - n_t + 0.5}{n_t + 0.5} \right)$$

$$\text{avgdl} = \frac{1}{N} \sum_i |d_i|$$

- N = Quantidade total de documentos
- n_t = Quantidade de documentos que contém o termo t
- $|d_i|$ = Tamanho do documento

A implementação desta função foi feita exatamente como descrito aqui, com uso das bibliotecas `math` e `numpy`. Sua implementação foi feita como classe, recebendo os seguintes parâmetros:

- Posting List - Instância da classe `PostingList`
- Pipeline Options - Seleção de modo de processamento das queries

Modelo Vetorial

O modelo vetorial consiste na seguinte função de ranqueamento:

$$\text{sim}(d, q) = \frac{\sum w_{dt} w_{qt}}{\sqrt{\sum w_{dt}^2} + \sqrt{\sum w_{qt}^2}}$$

Onde:

$$w = \begin{cases} (1 + \log(f(t))) \cdot \log\left(\frac{N}{n_t}\right), & \text{se } f(t) > 0 \\ 0, & \text{se } f(t) = 0 \end{cases}$$

- $f(t)$ - Frequência do termo no documento/query.

Para otimizar o tempo de execução do algoritmo, o vetor de pesos é montado utilizando somente os termos pertencentes à query, com valor igual a zero caso algum dos termos seja inexistente no documento. Assim, se existem `n` termos na query, o vetor de qualquer documento selecionado terá dimensionalidade `n`, assim como o vetor de pesos da query.

A implementação desta função foi feita exatamente como descrito aqui, com uso das bibliotecas `math` e `numpy`. Sua implementação foi feita como classe, recebendo os seguintes parâmetros:

- Posting List - Instância da classe `PostingList`
- Pipeline Options - Seleção de modo de processamento das queries

Avaliação dos modelos

O dataset utilizado pode ser acessado em IR Datasets: Cranfield. Para avaliação dos modelos, foram utilizadas todas as queries do dataset.

As métricas utilizadas para avaliação foram $P@k$, $R@k$ e $MAP@k$. Os gráficos e análises consistem na comparação dessas métricas entre diferentes condições e modelos. As métricas finais apresentadas são a média das métricas que cada query retornou, devido à alta quantidade de queries utilizadas para avaliação (mas que permite uma melhor análise de cada modelo).


Resultados obtidos e Análise

Comparação entre Modelo Vetorial e Modelo Probabilístico

Para realizar a comparação entre os dois modelos, o modelo probabilístico recebeu parâmetros fixos $k = 1.2$ e $b = 1.0$. As métricas utilizadas para comparação foram Precision, Recall e MAP.

Curva Precision x Recall

Na curva do gráfico Precision x Recall, cada ponto representa um top-k, com $P@k$ e $R@k$ definidos como a média de todas as queries executadas.



Analisando a figura, é fácil averiguar que, em todos os casos, **o modelo probabilístico foi superior ao vetorial** com uma boa margem entre o pior do modelo probabilístico e o melhor do modelo vetorial (cerca de 5%).

Para o modelo **probabilístico**, existem duas duplas de grupos semelhantes: `WithStopRemovalWithStemming` e `NoStopRemovalWithStemming` apresentaram desempenho semelhante e claramente superior a `WithStopRemovalNoStemming` e `NoStopRemovalNoStemming` (também semelhantes). Isso evidencia que o tratamento de strings que afeta mais positivamente o modelo é a aplicação do stemming. Ao final da curva, é possível ver que a remoção de stop words forneceu uma pequena vantagem de modo geral.


Para o modelo **vetorial**, também existem duas duplas de grupos semelhantes, mas comportamento inverso: `WithStopRemovalWithStemming` e `NoStopRemovalNoStemming` foram superiores a `WithStopRemovalNoStemming` e `NoStopRemovalWithStemming`. Isso evidencia que, no modelo vetorial, o tratamento mais significativo é a remoção de stop words. O stemming fornece apenas uma pequena vantagem de modo geral.

Dadas as observações, pode-se aferir a causa.

No modelo **probabilístico**, a variação pequena ao alternar a aplicação da remoção de stop words evidencia que o modelo lida muito bem com palavras que se repetem em quase todos os arquivos, conseguindo reduzir sua relevância ao nível esperado. Isto provavelmente se deve ao parâmetro de penalização por **tamanho do documento**.

Já a grande variação na presença do stemming pode transparecer um defeito: O modelo é facilmente influenciável pela frequência dos termos, ganhando eficiência quando os termos são agrupados (“andar”, “andou”, “andei” -> “and”), o que retira a influência de termos únicos. Para testar essa hipótese, foi aplicado $\log$ aos termos de frequência da equação do BM25, de modo que:

$$\text{score}(d, q) = \sum_{t \in q} \text{IDF}(t) \frac{\log(1 + tf(t, d))(k_1 + 1)}{(\log(1 + tf(t, d)) + k_1 \left(1 - b + \left(\frac{b(|d|)}{\text{avgl}}\right)\right))}$$



O desempenho do BM25 diminuiu. Mas note que a divisão em duplas por presença de stemming já praticamente não existe mais: os desempenhos se aproximaram, de modo que apenas stemming e apenas remoção de stop words apresentaram desempenho próximo a partir de k=5. Isso confirma a sensibilidade do BM25 a termos muito frequentes no documento, mas também mostra que essa sensibilidade é necessária para sua eficiência.


No modelo **vetorial**, a variação pequena ao alternar a aplicação de stemming pode evidenciar um ponto forte do modelo: Quanto a frequência das palavras no documento correlatas à query aumenta muito, o modelo lida bem com isso. Diferente de stop words, palavras com stemming se aproximam e identificam melhor documentos com temas específicos (“medicar”, “medicando”, “medicamento” -> “medic”). Isso não é tratado pelo **IDF**, mas sim pelo logaritmo que amortece a influência da frequência do termo no peso final.

Já a grande variação ao alternar a remoção de stop words transparece um defeito do modelo vetorial: Como stop words são muito comuns entre query e documento, o vetor de ambos começa a ficar poluído e com ruídos, piorando drasticamente a acurácia do modelo devido a dimensões extras

desnecessárias. Isto provavelmente é uma falha da similaridade por cosseno, apesar do termo de controle **IDF**.

Comparação de MAP

Em ordem decrescente, as pontuações MAP para as variações do modelo probabilístico e vetorial se encontram no gráfico abaixo.



Novamente, o modelo probabilístico se mostra superior ao modelo vetorial.

No modelo probabilístico, o stemming se mostrou como mais relevante no incremento do MAP do que a remoção de stop words.

Já no modelo vetorial, a remoção de stop words se mostrou como mais relevante no incremento do MAP do que o stemming, mas com menor discrepância do que no modelo probabilístico.

O comportamento observado na curva de Precision x Recall se repete no MAP, fortalecendo as hipóteses apresentadas.

Análise por consulta

Serão selecionadas 2 consultas para cada modelo onde o resultado foi claramente discrepante (de modo positivo). O pipeline utilizado foi o completo `WithStopRemovalWithStemming`. Os parâmetros utilizados para o modelo probabilístico foram $k = 1.2$ e $b = 1.0$.

Consultas com BM25 superior

Query 52: `what is the available information pertaining to the effect of slight rarefaction on boundary layer flows (the ?slip? effect) .`

- BM25 MAP: 0.875
- Vetorial MAP: 0.12

1. Doc 326 [RELEVANT]
2. Doc 21 [RELEVANT]
3. Doc 306 [RELEVANT]
4. Doc 265 [IRRELEVANT]
5. Doc 1215 [IRRELEVANT]

Query 146: does a membrane theory exist by which the behaviour of pressurized membrane cylinders in bending can be predicted .

- BM25 MAP: 0.75
- Vetorial MAP: 0.24

1. Doc 1045 [RELEVANT]
2. Doc 955 [IRRELEVANT]:
3. Doc 1130 [IRRELEVANT]:
4. Doc 840 [RELEVANT]:
5. Doc 854 [IRRELEVANT]

As duas queries possuem termos técnicos precisos ou palavras-chave exatas.

Consultas com Modelo Vetorial superior

Query 133 : experimental studies of creep buckling .

- BM25 MAP: 0.23
- Vetorial MAP: 0.59

1. Doc 1019 [RELEVANT]
2. Doc 1016 [RELEVANT]
3. Doc 951 [IRRELEVANT]
4. Doc 1018 [RELEVANT]
5. Doc 1025 [IRRELEVANT]

Query 167 : exact solution methods for calculating the ablative mass loss of a material ablating at high temperatures in a hypersonic flight environment .

- BM25 MAP: 0.41
- Vetorial MAP: 0.75

1. Doc 274 [RELEVANT]
2. Doc 1279 [IRRELEVANT]
3. Doc 908 [IRRELEVANT]
4. Doc 82 [RELEVANT]
5. Doc 576 [IRRELEVANT]

As duas queries associam conceitos, com proximidade temática (“creep buckling”, “ablative mass loss”).

Consultas com desempenho insatisfatório em ambos

Query 31 : what size of end plate can be safely used to simulate two-dimensional flow conditions over a bluff cylindrical body of finite aspect ratio .

- BM25 MAP: 0.00074
- Vetorial MAP: 0.00077

1. Doc 751 [IRRELEVANT]:
2. Doc 1153 [IRRELEVANT]:
3. Doc 1209 [IRRELEVANT]:
4. Doc 228 [IRRELEVANT]
5. Doc 1245 [IRRELEVANT]

Query 22 : did anyone else discover that the turbulent skin friction is not over sensitive to the nature of the variation of the viscosity with temperature .

- BM25 MAP: 0.0010
- Vetorial MAP: 0.0017

1. Doc 125 [IRRELEVANT]
2. Doc 560 [IRRELEVANT]
3. Doc 254 [IRRELEVANT]
4. Doc 413 [IRRELEVANT]
5. Doc 307 [IRRELEVANT]


As duas consultas são longas e no formato de pergunta em linguagem comum (“what size of end plate...”, “did anyone else...”)


Variação de parâmetros do BM25

Foram estudadas variações dos parâmetros k_1 e b do modelo probabilístico. As variações são concernentes a $k_1 \in \{0.5, 1.2, 2.0\}$ e $b \in \{0, 0.75, 1\}$

MAP agrupado por parâmetros

Primeiro, é útil verificar como cada parâmetro se saiu nos pipelines.





De modo geral, são feitas as seguintes observações (aplicáveis somente ao universo de k e b testados):


1. A remoção de stop words junto com o stemming se estabelece em definitivo como o melhor tipo de processamento para todas as variações do BM25.
2. A ausência da remoção de stop words e de stemming se estabelece em definitivo como o pior tipo de processamento para todas as variações do BM25.
3. Somente stemming foi o segundo melhor processamento em definitivo, exceto quando $b = 0.0$. Nesse caso, a remoção de stop words se define como o segundo melhor processamento.
4. Para todo k , todos os scores são significativamente melhores para $b = 0.75$ em comparação a $b = 0.0$.
5. Para todo k , todos os scores são desprezivelmente melhores e, por vezes, desprezivelmente piores para $b = 1.0$ em comparação a $b = 0.75$, mas com $b = 0.75$ sempre melhor que $b = 0.0$ para o mesmo k .
6. Para todo b , todos os scores são melhores para $k = 1.2$ em comparação a $k = 0.5$.
7. Para $b = 0.75$ e $b = 1.0$, todos os scores são levemente melhores para $k = 2.0$ em comparação a $k = 1.2$. Para $b = 0.0$, isso varia entre leve melhora/piora.

As observações 1 e 2 já eram esperadas. A observação 3 mostra que a ausência do parâmetro b (penalidade por tamanho do documento) representa um problema quando não há remoção de stop words, de modo que somente a remoção de stop words se destaca frente ao stemming. Pela observação 4, também pode-se afirmar que a presença do parâmetro b sempre resulta em melhora significativa na precisão. Por último, a observação 5 revela uma saturação do parâmetro b , de modo que penalizar demais pelo tamanho do documento resulta em perda de precisão.

As observações 6 e 7 revelam, igualmente, uma saturação do parâmetro k .

Mapa de bolhas P@10 x R@10

Ao verificar o comportamento para Precision x Recall ao longo de $k=1$ até $k=10$, a ordem do score das variações se manteve estável, de modo que pode-se analisar somente $k=10$ e inferir o mesmo para $k < 10$.



Em todos os casos, percebe-se, referente ao pipeline, uma ordem de eficiência: `WithStopRemovalWithStemming > NoStopRemovalWithStemming > WithStopRemovalNoStemming > NoStopRemovalNoStemming`

Essa observação foi feita em todas as análises anteriores.

No geral, percebe-se que as variações 5,6,8,9 sempre estão à frente das outras em todos os casos, alternando entre si. Assim, é válido considerá-los as melhores opções possíveis.

O melhor caso possível é `WithStopRemovalWithStemming` com $k = 1.0$ e $b = 0.75$.

Modificação de queries

- Query 1: what similarity laws must be obeyed when constructing aeroelastic models of heated high speed aircraft .
- Query 1 (**alternativa**): what similarity laws must be obeyed when construction aereoelastic models of aricraft .
- Query 2: what are the structural and aeroelastic problems associated with flight of high speed aircraft .
- Query 2 (**alternativa**): what are the aeroelastic problems associated with flight of high speed aircraft
- Query 3: what problems of heat conduction in composite slabs have been solved sonfar .

- Query 3 (**alternativa**): what problems of transient heat conduction in composite slabs have been solved so far .
- Query 5: what chemical kinetic system is applicable to hypersonic aerodynamic problems .
- Query 5 (**alternativa**): what chemical kinetic mechanism is applicable to hypersonic aerodynamic problems .
- Query 12: how can the aerodynamic performance of channel flow ground effect machines be calculated .
- Query 12 (**alternativa**): how can the aerodynamic performance of ground effect machines be calculated .

O top 101 será mostrado como ele é dado pelo modelo: um array ordenado de `doc_ids` , com um bit `0` ou `1` para indicar se o documento é relevante.

BM25

Query 1:

```
[('51', 1), ('486', 0), ('878', 0), ('12', 1), ('573', 0), ('944', 0), ('746', 0), ('879', 1), ('141', 0), ('747', 0)]
```

Query 1_mod:

```
[('51', 1), ('486', 0), ('573', 0), ('878', 0), ('12', 1), ('944', 0), ('875', 1), ('359', 0), ('184', 1), ('219', 0)]
```

Remover “heated high speed aircraft” não alterou o top 1 relevante, tirou uma posição do top 4 e trouxe 2 documentos relevantes diferentes, mas perdeu 1 que havia recuperado. Em média, o modelo BM25 lida bem com a falta de palavras.

Query 2:

```
[('12', 1), ('746', 1), ('51', 1), ('1089', 0), ('1169', 0), ('100', 0), ('172', 0), ('810', 0), ('1380', 0), ('700', 0)]
```

Query 2_mod:

```
[('12', 1), ('746', 1), ('1089', 0), ('1169', 0), ('172', 0), ('810', 0), ('700', 0), ('51', 1), ('14', 1), ('1158', 0)]
```

Remover “structural” não alterou o top 2 e fez um documento relevante no top3 perder posições, mas trouxe mais um documento relevante. A consulta piorou.

Query 3:

```
[('485', 0), ('5', 1), ('399', 1), ('144', 1), ('181', 1), ('91', 1), ('90', 1), ('579', 0), ('6', 1), ('542', 0)]
```

Query 3_mod:

```
[('5', 1), ('485', 0), ('399', 1), ('144', 1), ('91', 1), ('6', 1), ('181', 1), ('90', 1), ('579', 0), ('980', 0)]
```

Adicionar “transient” manteve todos os documentos relevantes anteriormente resgatados no top 10, colocou um documento relevante na primeira posição no lugar de um não relevante, e o resto apenas permutou. Adicionar “transient” deixou a consulta mais sólida.

Query 5:

```
[('103', 0), ('1032', 0), ('401', 1), ('943', 0), ('552', 1), ('1296', 1), ('968', 0), ('625', 0), ('1374', 0), ('746', 0)]
```

Query 5_mod:

```
[('1296', 1), ('401', 1), ('103', 0), ('625', 0), ('552', 1), ('1374', 0), ('837', 0), ('746', 0), ('488', 0), ('707', 0)]
```

Trocar “system” por “mechanism” alterou drasticamente o ranking, colocando dois dos três documentos relevantes no top2 e mantendo um intacto. Muito provavelmente “mechanism” é mais discriminativo.

Query 12:

```
[('650', 1), ('624', 0), ('966', 0), ('1232', 0), ('1221', 0), ('941', 0), ('939', 0), ('1164', 0), ('652', 1), ('270', 0)]
```

Query 12_mod:

```
[('650', 1), ('624', 0), ('1232', 0), ('1164', 0), ('543', 0), ('704', 0), ('652', 1), ('1223', 0), ('1094', 0), ('506', 0)]
```

Remover “channel flow” manteve o top 1 relevante e melhorou duas posições do próximo documento relevante. O modelo BM25 lida bem com a falta de palavras específicas.

Modelo vetorial

Query 1:

```
[('573', 0), ('329', 0), ('944', 0), ('486', 0), ('12', 1), ('1194', 0), ('78', 0), ('51', 1), ('14', 1), ('414', 0)]
```

Query 1_mod:

```
[('573', 0), ('329', 0), ('944', 0), ('1194', 0), ('486', 0), ('414', 0), ('78', 0), ('14', 1), ('51', 1), ('202', 0)]
```

Remover “heated high speed aircraft” piorou a posição dos relevantes, perdendo um em comparação ao original. Remover muitas palavras específicas piora drasticamente a qualidade do modelo vetorial.

Query 2:

```
[('12', 1), ('78', 0), ('14', 1), ('172', 0), ('746', 1), ('202', 1), ('1089', 0), ('1380', 0), ('486', 0), ('914', 0)]
```

Query 2_mod:

```
[('12', 1), ('14', 1), ('172', 0), ('78', 0), ('746', 1), ('1089', 0), ('914', 0), ('141', 0), ('202', 1), ('364', 0)]
```

Remover “structural” melhorou em 1 posição o top3 relevante, desceu 3 posições do top6 relevante e manteve os outros intactos. Remover palavras piora a consulta.

Query 3:

```
[('485', 0), ('399', 1), ('5', 1), ('144', 1), ('579', 0), ('91', 1), ('625', 0), ('90', 1), ('1072', 0), ('344', 0)]
```

Query 3_mod:

```
[('5', 1), ('91', 1), ('485', 0), ('399', 1), ('144', 1), ('579', 0), ('625', 0), ('90', 1), ('6', 1), ('1072', 0)]
```

Adicionar “transient” melhorou a posição, em geral, dos relevantes e trouxe mais um. Adicionar palavras específicas melhorou a consulta.

Query 5:

```
[('401', 1), ('625', 0), ('103', 0), ('943', 0), ('328', 0), ('552', 1), ('1296', 1), ('1147', 0), ('1072', 0), ('77', 0)]
```

Query 5_mod:

```
[('625', 0), ('1296', 1), ('1072', 0), ('401', 1), ('328', 0), ('552', 1), ('103', 0), ('357', 0), ('943', 0), ('976', 0)]
```

Trocar “system” por “kinect” praticamente inverteu o top1 e top7, mantendo o top6 intacto. Provavelmente o que veio à frente possuía “kinect” (ou em maior quantidade).

Query 12:

```
[('624', 0), ('966', 0), ('1232', 0), ('650', 1), ('325', 0), ('792', 0), ('506', 0), ('939', 0), ('704', 0), ('810', 0)]
```

Query 12_mod:

```
[('624', 0), ('1232', 0), ('650', 1), ('325', 0), ('792', 0), ('506', 0), ('810', 0), ('1168', 0), ('704', 0), ('717', 0)]
```

Remover “channel flow” melhorou em 1 posição o único documento relevante. Provavelmente o que estava à frente tinha alguma das duas palavras.

Análise de erros

Top 1 não relevante para BM25

Query

5,

BM25: `what chemical kinetic system is applicable to hypersonic aerodynamic problems.`

Retornou `doc_id=103` em primeiro no ranking, sendo que é um documento não relevante.

Após o processamento:

```
{'chemic': 1, 'kinet': 1, 'system': 1, 'applic': 1, 'hyperson': 1, 'aerodynam': 1, 'problem': 1}
```

Ranking:

```
[('103', 0), ('1032', 0), ('401', 1), ('943', 0), ('552', 1), ('1296', 1), ('968', 0), ('625', 0), ('1374', 0), ('746', 0)]
```

Doc `103` após o processamento:

```
{'theori': 1, 'mix': 2, 'chemic': 3, 'reaction': 1, 'oppos': 1, 'jet': 3, 'diffus': 1, 'flame': 3, '': 7, 'ideal': 1, 'flow': 3, 'system': 1, 'use': 1, 'potter': 2, 'butler': 2, 'analyz': 2, 'differenti': 2, 'equat': 2, 'solv': 1, 'exactli': 1, 'give': 1, 'locat': 1, 'burn': 1, 'rate': 3, 'solut': 1, 'kinet': 2, 'discuss': 1, 'relat': 1, 'deriv': 1, 'extinct': 2, 'constant': 1, 'laminar': 1, 'speed': 1, 'premix': 1, 'gase': 1, 'shown': 1, 'independ': 1, 'transport': 1, 'propti': 1, 'comparison': 1, 'made': 1, 'experiment': 1, 'data': 1, 'heimel': 1, 'argu': 1, 'experi': 1, 'must': 1, 'carri': 1, 'higher': 1, 'reynold': 1, 'number': 1, 'measur': 1, 'quantit': 1}
```

Analisando a interseção:

```
{'chemic': 3, 'system': 1, 'kinet': 2}
```

Doc 401 (primeiro relevante):

```
{'inviscid': 4, 'hyperson': 3, 'airflow': 3, 'coupl': 4, 'nonequilibrium': 4,
'process': 3, '': 16, 'analys': 1, 'made': 1, 'effect': 1, 'chemic': 2, 'rate': 2,
'extern': 1, 'high': 1, 'enthalpi': 1, 'level': 3, 'exact': 3, 'numer': 1, 'solut':
3, 'obtain': 1, 'invers': 1, 'method': 1, 'nearspher': 1, 'nose': 7, 'flight': 1,
'condit': 2, 'substanti': 1, 'prevail': 1, 'region': 2, 'typic': 1, 'consid': 3,
'includ': 3, 'radii': 1, 'order': 1, 'l': 1, 'ft': 3, 'altitud': 2, '250000': 1,
'veloc': 4, '15000': 1, '23000': 1, 'per': 1, 'sec': 1, 'result': 2, 'illustr': 1,
'gener': 1, 'import': 3, 'among': 1, 'reaction': 4, 'dissociationrecombin': 1,
'bimolecularexchang': 1, 'ioniz': 1, 'show': 1, 'bimolecular': 1, 'exchang': 1,
'bluntnos': 2, 'flow': 5, 'kinet': 2, 'n': 1, 'case': 1, 'plane': 2, 'shock': 4,
'wave': 1, 'differ': 1, 'howev': 1, 'gasdynam': 1, 'expans': 2, 'curv': 1, 'layer':
2, 'former': 1, 'reduc': 1, 'postshock': 1, 'consequ': 1, 'regim': 2, 'studi': 1,
'oxygen': 1, 'nitrogenatom': 1, 'concentr': 1, 'tend': 1, 'freez': 1, 'infiniter':
1, 'equilibrium': 2, 'reduct': 1, 'dissoci': 2, 'larg': 1, 'particularli': 1,
'nitrogen': 1, 'higher': 1, 'domin': 1, 'twobodi': 1, 'collis': 1, 'phenomena': 2,
'thu': 1, 'amen': 1, 'binari': 2, 'scale': 4, 'given': 2, 'demonstr': 1, 'rang':
1, 'correl': 1, 'constant': 1, 'product': 1, 'ambient': 1, 'densiti': 1, 'radiu':
1, 'similitud': 1, 'also': 1, 'viscou': 1, 'radiat': 1, 'provid': 1, 'use': 1,
'flexibl': 1, 'test': 1, 'applic': 1, 'afterbodi': 1, 'inviscidflow': 1, 'problem':
1, 'briefli': 1, 'discuss': 1, 'light': 1}
```

Intersecção:

```
{'chemic': 2, 'kinet': 2, 'n': 1, 'problem': 1}
```

É fácil analisar que o documento irrelevante foi colocado no top 1 por dois motivos: possui maior frequência de palavras e menor tamanho de documento. Além disso, o documento relevante tem muitos termos muito específicos que poderiam ter sido utilizados na query. O modelo probabilístico se mostra ineficiente na falta de termos-chave. Mesmo que existam muitos termos similares a “aerodynam”, como “flight”, eles são ignorados.

Top 1 não relevante para modelo vetorial

Query 3, modelo vetorial: what problems of heat conduction in composite slabs have been solved sonfar. Retornou doc_id=485 em primeiro no ranking, sendo que é um documento não relevante.

Após o processamento:

```
{'problem': 1, 'heat': 1, 'conduct': 1, 'composit': 1, 'slab': 1, 'solv': 1,
'sonfar': 1}
```

Ranking:

```
[('485', 0), ('399', 1), ('5', 1), ('144', 1), ('579', 0), ('91', 1), ('625', 0),
('90', 1), ('1072', 0), ('344', 0)]
```

Doc 485 após o processamento:

```
{'linear': 2, 'heat': 2, 'flow': 1, 'composit': 2, 'slab': 2, '': 2, 'temperatur': 2, 'determin': 1, 'function': 2, 'posit': 1, 'time': 1, 'case': 1, 'conduct': 1, 'ture': 1, 'throughout': 1, 'two': 1, 'extern': 1, 'surfac': 1, 'consid': 1, 'prescrib': 1}
```

Intersecção:

```
{'heat': 2, 'composit': 2, 'slab': 2, 'conduct': 1}
```

Doc 399 (primeiro relevante) após o processamento:

```
{'conduct': 1, 'heat': 3, 'composit': 1, 'slab': 1, '': 2, 'method': 1, 'calcul': 1, 'total': 1, 'quantiti': 1, 'pass': 1, 'unit': 1, 'area': 1, 'zero': 2, 'time': 2, 'develop': 1, 'allow': 1, 'made': 1, 'surfac': 1, 'resist': 3, 'regard': 1, 'contact': 1, 'addit': 1, 'layer': 1, 'appropri': 1, 'thermal': 1, 'capac': 1}
```

Intersecção:

```
{'conduct': 1, 'heat': 3, 'composit': 1, 'slab': 1}
```

O doc 485 ganha por ter uma frequência maior frente à mesma intersecção de termos entre documento e query.

Documento relevante omitido no modelo vetorial

Query 1 modificada:

what similarity laws must be obeyed when constructing aeroelastic models of aircraft .

Ranking: doc_id=13 relevante na posição 50.

Após o processamento:

```
{'similar': 1, 'law': 1, 'must': 1, 'obey': 1, 'construct': 1, 'aeroelast': 1, 'model': 1, 'aircraft': 1}
```

Doc 13 após o processamento:

```
{'similar': 3, 'law': 2, 'stress': 3, 'heat': 5, 'wing': 3, '': 6, 'shown': 1, 'differenti': 1, 'equat': 1, 'plate': 5, 'larg': 1, 'temperatur': 2, 'gradient': 1, 'constant': 1, 'made': 1, 'proper': 1, 'modif': 1, 'thick': 1, 'load': 3, 'isotherm': 1, 'fact': 1, 'lead': 1, 'result': 1, 'calcul': 1, 'measur': 1, 'strain': 1, 'unheat': 2, 'seri': 1, 'relat': 1, 'call': 1, 'applic': 1, 'analog': 3, 'theori': 1, 'solid': 1, 'aerodynam': 1, 'discuss': 2, 'detail': 1, 'howev': 1, 'complic': 1, 'involv': 1, 'novel': 1, 'concept': 1, 'feedback': 1, 'bodi': 1, 'forc': 1, 'problem': 1, 'boxw': 1, 'structur': 1, 'solv': 1, 'method': 1, 'briefli': 1}
```

Intersecção com query:

```
{'similar': 3, 'law': 2}
```

O modelo vetorial falha em resgatar o documento pois há poucos termos na intersecção (apenas 2, 25% do total). O fato de haver alta frequência não possui muito impacto por conta do IDF.

Conclusão

Pela análise da curva Precision x Recall, pode-se concluir que o modelo probabilístico BM25 é superior ao modelo vetorial. Além disso, eles são afetados pelo pipeline escolhido:

- No modelo **probabilístico**, o tratamento mais relevante é o stemming. A remoção de stop words possui baixa relevância, sendo mais decisivo nos primeiros resultados e se tornando quase inperceptível nos resultados posteriores. Verificou-se que a sensibilidade da presença do stemming é atenuada pela aplicação da operação de log na frequência do termo no denominador e numerador, mas diminui a eficácia.
- No modelo **vetorial**, o tratamento mais relevante é a remoção de stop words. O stemming possui baixa relevância, mas ainda assim é um fator discrepante ao longo de toda a curva. A presença de muitas palavras repetidas e frequentes se mostrou um ponto negativo para o cálculo de score por similaridade de cosseno.

O MAP da comparação entre probabilístico e vetorial confirma a superioridade do modelo probabilístico, além de confirmar os pipelines realmente relevantes para cada modelo, confirmando o que foi observado na curva Precision x Recall.

Na análise por consulta, pode-se verificar um padrão:

- O BM25 é superior quando a query contém **termos técnicos precisos** ou **palavras-chave exatas e discriminantes** (“rarefaction”, “slip”, “pressurized membrane cylinders”).
- O modelo vetorial é superior quando a query exige **associação de conceitos/tokens**: “creep buckling”, “ablative mass loss”.
- Os dois modelos tiveram um desempenho quase nulo quando a query era uma **pergunta natural**: “what size of end plate...”, “did anyone else discover...”. Isso mostra que perguntas naturais são ruidosas por causa da **presença de termos muito comuns e pronomes**, como “what”, “can”, “be”, etc.

Ao variar parâmetros no BM25, concluiu-se que tanto k_1 quanto b saturam e possuem máximo desempenho em um ponto intermediário, denotado como $k = 1.2$, $b = 0.75$. Para todos os casos, o pipeline completo `WithStopRemovalWithStemming` se mostra mais uma vez como o mais eficiente, e o contrário (sem tratamento), como o mais ineficiente.

A ausência do parâmetro b (penalidade do tamanho por documento) se mostrou muito negativa quando não há remoção de stop words, de modo que somente a remoção de stop words gera resultados melhores que só stemming nessa ocasião. Assim, o parâmetro b se mostrou capaz de estabilizar a acurácia do modelo em função de documentos muito longos ou com muitas palavras repetidas.

Nas modificações de queries, o BM25 mantém a estabilidade da consulta quando termos são removidos, e adicionar termos ou trocar termos por outros similares porém mais específicos se mostraram técnicas capazes de melhorar a posição dos documentos relevantes no ranking. Por outro lado, o modelo Vetorial perde muito mais desempenho quando palavras são removidas da query. Trocar palavras por mais específicas não melhora o ranking em geral, apenas alterna documentos (comportamento vetorial característico que aproxima termos similares no espaço vetorial, garantindo um score próximo). Adicionar termos melhora a posição dos documentos relevantes.

Na análise de erros:

- Para uma query do BM25, um documento irrelevante foi colocado no top 1 por ter maior frequência de tokens presentes na query e menor tamanho de documento. Além disso, o modelo falhou em dar relevância ao documento realmente relevante por não considerar termos semanticamente próximos (como “aerodynamics” e “flight”).
- Para uma query do modelo vetorial, Um documento irrelevante foi colocado no top 1 por ter uma frequência maior dentre a mesma intersecção de termos para o top 2, que por sua vez é relevante. Além disso, termos semanticamente próximos no documento relevante foram ignorados (como “thermal” e “heat”).
- Para o documento relevante omitido no modelo vetorial, a falha na recuperação se dá pela baixa intersecção de termos entre query e documento. Novamente, palavras semanticamente próximas foram ignoradas.

O principal motivo de erros é a falha dos dois modelos clássicos em considerar palavras semanticamente próximas às da query. Essa medida direta é prejudicial para a compreensão dos arquivos e, por sua vez, para a sua recuperação e ranking.

Uso de ferramentas de IA

O modelo generativo Gemini foi utilizado para:

- Criação de código-base para plotar gráficos
- Verificação de implementação correta dos modelos clássicos
- Geração de script para tratar dados gerados pelo `experiments.py` e obter as melhores/piores queries do BM25 frente ao modelo vetorial, além das piores em ambos.

O sistema de RI foi implementado manualmente. A inteligência artificial foi utilizada para poupar trabalho desnecessário e permitir um tempo maior para análise dos resultados.